

Modélisation Multidimensionnelle et Entrepôt de Données

Sujet : Etude Des accidents en Royaume-Uni

Réalisé par :

Ben Salem Rihab

Mouelhi Ayoub

Soutenu Le 23/06/2020 devant le professeur :

M. Ben HajKasem Mohamed Aymen

Remerciement

Nous tenons à remercier dans un premier temps, toute l'équipe pédagogique de l'institut supérieur de gestion et les intervenants professionnels responsables de la formation informatique décisionnelle. Avant d'entamer ce rapport, nous profitons de l'occasion pour remercier tout d'abord notre professeur Monsieur Ben HajKasem Mohamed Aymen qui n'a pas cessé de nous encourager pendant la durée du projet. Nous le remercions également pour l'aide et les conseils concernant les missions évoquées dans ce rapport, qu'il nous a apporté lors des différents suivis, et la confiance qu'il nous est témoigné. Nous tenons à remercier notre professeur de nous avoir incités à travailler en mettant à notre disposition leurs expériences et leurs compétences.

Table de matières :

Chapitre 1 : Analyse et spécifications des besoins.

- 1. Problématique
- 2. Critique de l'existant
- 3. Netographie
- 4. Stockage des données

Chapitre 2 : Conception du modèle multidimensionnel.

- I. Niveau d'abstraction
 - 1. Conceptuel
 - 2. Logique
 - 3. Physique
- II. Modélisation Multidimensionnel
- III. Modélisation d'un DataWerhouse
 - a. En étoile
 - b. En flocon

Chapitre 3 : Réalisation de la solution.

- I. Intégration des données à l'aide d'ETL open source
- II. Notre objectif
- III. Solution

Chapitre 4 : Conclusion.

Chapitre 1: Analyse et Spécifications des Besoins

I. Introduction:

Un accident corporel (mortel et non mortel) de la circulation routière un accident qui :

- provoque au moins une victime c'est-à-dire un usager ayant nécessité des soins médicaux
- survient sur une voie ouverte à la circulation publique
- implique au moins un véhicule.

Les définitions des victimes :

Les tués : toute personne qui décédera sur le coup ou dans les trente jours qui suivent l'accident.

- Les blessés hospitalisés : victimes admises comme patients dans un hôpital plus de 24 heures.
- Les blessés non hospitalisés : victimes ayant fait l'objet de soins médicaux mais n'ayant pas été admis comme patients à l'hôpital plus de 24 heures.

1. Problématique :

On souhaite mettre en place un système d'information décisionnelle pour observer le registre des victimes d'accidents corporels de la circulation routière.

Notre objectif aussi est de pouvoir analyser le taux des personnes affectées ainsi que le taux de gravité d'accidents par date, lieu, Age...

2. Critique de l'existant :

Entre les taux de mortalité et la motorisation, plusieurs études ont montré qu'il existe une corrélation entre l'augmentation du nombre des véhicules automobiles et celle des accidents de la circulation et des traumatismes qui en résultent, aussi la vitesse excessive ou inappropriée, qui est généralisée, peut contribuer à environ 30 % des accidents de la circulation et des décès qui en résultent. En cas de collision à 80 km/h, les occupants des voitures risquent 20 fois plus d'être tués qu'à 30 km/h.

84 525 accidents corporels

108 076 blessés dont 39 811 hospitalisés


5 318 tués à 30 jours

Facteurs de risque influant sur les accidents :


Vitesse/ Risque d'accident/ Gravité des traumatismes dus aux accidents/ Alcool/ Age des conducteurs/ Médicaments et drogues à usage récréatif/ Fatigue du conducteur/ Téléphones cellulaires/ Manque de visibilité/ Facteurs relatifs à la route/ Négligence de la sécurité dans la conception des routes

3. Netographie:

https://www.crashmap.co.uk/



Le site web **crashmap** contient des informations sur les accidents signalés depuis 1999 Il affiche tous les détails sur les lieux de collision, Les dates, les heures et le nombre de victimes et de véhicules associés



https://www.kaggle.com/stefanoleone992/adm-project-road-accidents-in-uk

Basé sur le site web crashmap.co.uk on a extraire des données similaires depuis kaggle sous forme CSV pour simplifier l'étude.

Le schéma relationnel de la base de données opérationnelle :

Clé primaire : La clé primaire d'une relation est une de ses clés candidates. Pour signaler la clé primaire, ses attributs sont généralement soulignés.

Clé étrangère : Une clé étrangère dans une relation est formée d'un ou plusieurs attributs qui constituent une clé primaire dans une autre relation.

Schéma relationnel : Un schéma relationnel est constitué par l'ensemble des schémas de relation.

Base de données relationnelle : Une base de données relationnelle est constituée par l'ensemble des n-uplets des différentes relations du schéma relationnel.

Conducteur

 $(\textbf{id_conducteur}, prenom, Nom, Genre, profession, Adresse, code_permis, groupe_sanguin, Age)\\$

| prénom | Nom | Genre | profession | Adresse | code_permis | groupe_sanguin | Age |
|---------|------------|--------|-------------------|------------------------------|-------------------|----------------|-----|
| Preston | Harper | Male | Meteorologist | 31 Treharne Street, Pentre | 1G4CW54K944359653 | 0+ | 47 |
| Stella | Baker | female | Electrician | 65 Doyle Avenue, Cardiff | KMHGN4JE4FU181098 | A+ | 68 |
| Luke | Brown | Female | Graphic Designer | 5A James Close, Bryncethin | WA1CM74L99D697859 | 0+ | 66 |
| Abigail | Harris | Female | Interior Designer | 10 Brython Drive, St Mellons | WAUJC68E62A601597 | 0- | 77 |
| Julia | Richardson | female | Physicist | 2 Blundell Court, Porthcawl | 1C3CDFCA7DD762995 | B+ | 72 |

Véhicule:

(id_veh,Age_vehicule,puissance,type_energie,Marque,type_vehicule,ref_proprietaire,num_assurance)

| Age_Vehicle | puissance | type_energie | Marque | type_véhicule | ref-propriétaire | num-assurance |
|-------------|-----------|--------------|------------|---------------|------------------|---------------|
| 8 | 1896 | Heavy oil | Volkswagen | Taxi | 4817 | 54908 |
| 3 | 599 | Petrol | Honda | Motorcycle | 5035 | 56127 |
| 8 | 1781 | Petrol | Audi | Car | 4658 | 55179 |
| 2 | 649 | Petrol | Other | Motorcycle | 5629 | 51965 |
| 12 | 600 | Petrol | Suzuki | Motorcycle | 5403 | 60424 |
| 2 | 2987 | Heavy oil | Mercedes | Car | 4729 | 54873 |

Accident(id_accident,Region,zone,vitesse_min,nature_route,condition_surface,climat,

lumiere, Date acc, nombre morts, taux gravite, nbre blesse, #id veh, #id cond)

| ref_Accident | Région | zone | vitesse_min nature_route | condition_surface | climat | lumiére | Date | nombre_morts taux de gravité | nbre_blessé |
|---------------|--------|-------|--------------------------|-------------------|--------|-------------------|------------------|------------------------------|-------------|
| 201001BS70015 | London | Urban | 30 Dual carriageway | Wet or damp | Fine | Darkness - lights | 2010-01-07 21:35 | 0 Slight | 2 |
| 201001BS70034 | London | Urban | 30 Single carriageway | Dry | Fine | Daylight | 2010-01-24 12:30 | 2 Slight | 0 |
| 201001BS70040 | London | Urban | 30 Single carriageway | Dry | Fine | Daylight | 2010-01-19 17:30 | 2 Slight | 3 |
| 201001BS70045 | London | Urban | 30 Single carriageway | Wet or damp | Other | Darkness - lights | 2010-01-27 18:15 | 2 Slight | 0 |
| 201001BS70060 | London | Urban | 30 Single carriageway | Wet or damp | Fine | Darkness - lights | 2010-02-05 6:10 | 2 Slight | 0 |
| 201001BS70065 | London | Urban | 30 Single carriageway | Dry | Fine | Daylight | 2010-02-08 11:24 | 0 Slight | 1 |
| 201001BS70104 | London | Urban | 30 Single carriageway | Dry | Fine | Daylight | 2010-03-03 6:25 | 1 Slight | 2 |

4. Stockage des données :

WampServer est une plateforme de développement Web de type WAMP, permettant de faire fonctionner localement (sans se connecter à un serveur externe) des scripts PHP

Phpmyadmin: c'une application Web de gestion pour les systèmes de gestion de base de données MySQL

Ces tables sont stockées dans la base de données Mysql nommée projet_input (taille=365 lignes)



Chapitre 2:

Conception du modèle multidimensionnel

I- Niveaux d'abstraction:

1- Conceptuel:



2- Logique : Mode de stockage

3- Physique: Processus d'alimentation

II- Modélisation Multidimensionnelle:

Description de la base multidimensionnelle indépendamment des choix d'implantation des Concepts :

 Dimensions : est tout ce qu'on utilisera pour faire nos analyses (Basé sur Clé primaire)

Dim_Date (id_date,secondes,minutes,Heure,jours,mois,année)

Dim_Conducteur (id_conducteur,Nom,prenom,sexe,Adresse,Profession,Age, num_permis)

Dim_Vehicule(id_vehicule,Age_vehicule,Marque,num_assurance,puissance,ref_proprietaire_type_energie,type_vehicule)

Dim_Route(id_route,nature_route,Region,zone)

Dim_Cause(id_cause,climat,condition_surface,vitesse_min,lumiere)

 Hiérarchie : Les attributs/membres d'une dimension sont organisés suivant des hiérarchies

Dimension temporelle: Secondes, minutes, jour, mois, année

Dimension géographique: Route, Region, zone

 Faits et mesures : Élément de donnée sur lequel portent les analyses, en fonction des différentes dimensions, Ces valeurs sont le résultat d'opérations d'agrégation (SUM, AVG, ...) sur les données(Basé sur clés étrangères des dimensions), plus les

entités mesurables qui nous servirons après lors de la génération du cube OLAP

Fact_accident(id_fact_accident,#id_conducteur,#id_date,#id_cause,#id_route, #id_vehicule,taux_personnes_affectees,taux_gravite)

Remarque : Taille Dimension << Taille Fait

III- Modèles d'un DataWarehouse:


Modélisation:

On a utilisé **StarUml** pour faire les modèles :


★ StarUml: c'est un logiciel de modélisation UML,il gère la plupart des diagrammes spécifiés

Au niveau conceptuel, il existe 2 modèles :

a. En étoile:



b. En flocon:



Chapitre3 : Réalisation de la solution

I. Intégration des données à l'aide d' ETL open source :

- ETL est l'acronyme de Extract Transform Load
- Un ETL combine en elle seule trois fonctionnalités : extraction depuis une source de données la transformation des données issues de l'étape précédente et enfin le chargement dans une nouvelle source de données

Dans notre cas on va utiliser Talend OpenStudio:

- https://www.talend.com/
- C'est un ETL de la société Talend
- C'est un projet open source
- C'est une application Eclipse plateforme

II. Notre Objectif:



III. Solution:

• Connexion à la base :

Paramétrer une connexion de type « MySQL » sous l'ETL Talend Open Studio afin de se connecter directement à la source de données « projet_input » et « projet_dw » ensuite on va récupérer le schéma(les tables).





Figure 1: connexion à la base


création et automatisation des Jobs :

Il suffit de créer un job et d'automatiser les jobs afin de déclencher la migration automatiquement, donc il suffit d'exécuter le job

Charger les dimensions:


Chaque table de dimension du datawarehouse ci dessus doit alimenter sa dimension correspondante





• Charger la table de faits:

La table de faits étant déjà alimentée par l'extraction des données sources, alors il reste de calculer les mesures



• Résultat au sein de la base de données:




• Restitution du cube OLAP :

Le chargement des dimensions et du contenu de la table de fait vers l'outil de restitution nécessite au préalable la construction du schéma du cube multidimensionnelle OLAP au niveau de l'outil « workbensh pentaho »


Pentaho: est un logiciel de business intelligence qui fournit l'intégration de données, les services OLAP, les rapports, les tableaux de bord d'informations, l'exploration et l'extraction de données, la transformation et le chargement

schema Workbench: est un logiciel de gestion et d'administration de bases de données MySQL créé en 2004

• Connexion à la base de données :



• Cube Olap:



Le cube qui a été construit à partir de la base de données est représenté par une structure XML. Elle comporte les dimensions, hiérarchies ainsi que les indicateurs (« Measures »).

```
<?xml version="1.0"?>
<Schema name="New Schema1">
     <Cube name="Cube OLAP Accident" enabled="true" cache="true" visible="true">
          <Table name="fact_accident" alias=""> </Table>
<Dimension name="dimension_cause" visible="true" foreignKey="id_cause" type="StandardDimension">
                <Hierarchy name="cause" visible="true" primaryKey="id_cause" hasAll="true"</p>
                      <Table name="dim_cause" alias=""> </Table>
<cevel name="id_cause" visible="true" type="Integer" levelType="Regular" uniqueMembers="false" nameColumn="id_cause" column="id_cause" table="dim_cause"> </Level>
                       <cevel name="vitesse_min" visible="true" type="Integer" levelType="Regular" uniqueMembers="false" nameColumn="vitesse_min" column="vitesse_min" table="dim_cause"> </Level</p>
                      <evel name="condition_surface" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="condition_surface" column="condition_surface" table="dim_cause"> </Level> <evel name="lumiere" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="lumiere" column="lumiere" table="dim_cause"> </Level></evel>
                       <Level name="climat" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="climat" column="climat" table="dim_cause"</p>
                </Hierarchy>
           </Dimension>
           <Dimension name="dimension_date" visible="true" foreignKey="id_date" type="TimeDimension">
               - <Hierarchy name="date" visible="true" primaryKey="id_date" hasAll="true"> <Table name="dim_date"> </Table>
                       <Level name="mois" visible="true" type="Numeric" levelType="TimeMonths" uniqueMembers='false" nameColumn="mois" column="mois" table="dim_date"> </Level>
                       <Level name="jours" visible="true" type="Numeric" levelType="TimeDays" uniqueMembers="false" nameColumn="jours" column="jours" table="dim_date"> </Level>
                       <Level name="annee" visible="true" type="Numeric" levelType="TimeYears" uniqueMembers="false" nameColumn="annee" column="annee" table="dim_date"> </Level</p>
                 </Hierarchy
           </Dimension>
         <Dimension name="Dimension_route" visible="true" foreignKey="id_route" type="StandardDimension">
                <Hierarchy name="route" visible="true" primaryKey="id_route" hasAll="true">
                       <Table name="dim_route" alias=""> </Table>
                       <a href="class"></a> <a href="class"><a href="class"><a
                       <Level name="nature_route" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="nature_route" column="nature_route" table="dim_route" > </Level>
                       <Level name="zone" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="zone" column="zone" table="dim_route"> </Level>
                 </Hierarchy>
        - <Dimension name="Dimension vehicule" visible="true" foreignKey="id vehicule" type="StandardDimension">
               · <Hierarchy name="vehicule" visible="true" primaryKey="id_vehicule" hasAll="true":
                       <Table name="dim_vehicule" alias="
                                                                                     </Table>
                      <Level name="marque" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="Marque" column="Marque" table="dim_vehicule"> </Level>


<Level name="type" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="type_vehicule" column="type_vehicule" table="dim_vehicule"> </Level>
<Level>
                       <Level name="energie" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="type_energie" column="type_energie" table="dim_vehicule"> </Level>
<Level name="puissance" visible="true" type="Integer" levelType="Regular" uniqueMembers="false" nameColumn="puissance" column="puissance" table="dim_vehicule"> </Level>
                       <Level name="age" visible="true" type="Integer" levelType="Regular" uniqueMembers="false" nameColumn="Age_Vehicule" column="Age_Vehicule" table="dim_vehicule" > </Level>
                 </Hierarchy>
           </Dimension>
          <Dimension name="Dimension_conducteur" visible="true" foreignKey="id_conducteur" type="StandardDimension">
                <Hierarchy name="conducteur" visible="true" primaryKey="id_cond" hasAll="true"</p>
                       <Table name="dim_conducteur" alias=""> </Table>
                       <Level name="nom" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="Nom" column="Nom" table="dim_conducteur"> </Level>
                      <elevel name="sexe" visible="true" type="String" levelType="Regular" unique/lembers="false" namecolumn="sexe" column="sexe" table="dim_conducteur"> </elevel>
<elevel name="age" visible="true" type="Numeric" levelType="Regular" unique/lembers="false" nameColumn="age" column="age" table="dim_conducteur"> </elevel>
<elevel name="profession" visible="true" type="String" levelType="Regular" unique/lembers="false" nameColumn="profession" column="profession" table="dim_conducteur"> </elevel>
<elevel name="profession" visible="true" type="String" levelType="Regular" unique/lembers="false" nameColumn="profession" column="profession" table="dim_conducteur"> </elevel>
                       <Level name="prenom" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="prenom" column="prenom" table="dim_conducteur"> </Level.</p>
                       <Level name="groupe_sanguin" visible="true" type="String" levelType="Regular" uniqueMembers="false" nameColumn="groupe_sanguin" column="groupe_sanguin" table="dim_conducteur"> </Level>
           <Measure name="taux personne affectée" visible="true" column="taux Personnes affectees" aggregator="sum" datatype="Numeric"> </Measure>
            <Measure name="taux_gravite" visible="true" column="taux_gravite" aggregator="distinct-count" datatype="String">
</Schema>
```

• Les tableaux de bord :

Dans cette partie on va générer des tableaux de bord adaptés aux différentes problématiques d'analyse à l'aide du PowerBI.


Power BI :est un service d'analyse commerciale de Microsoft. Il vise à fournir des visualisations interactives et des capacités de business intelligence avec une interface suffisamment simple pour que les utilisateurs finaux puissent créer leurs propres rapports et tableaux de bord

Figure Explication




Cette figure représente le taux de personnes affectées par année et son but est de donner une vision pour que le gouvernement décide si leur stratégie de l'année a bien marché


Nombre de taux_gravite par nature_route




Cette figure représente le taux de gravité par nature de route et que la nature du route a une influence sur la gravité de l'accident




Cette figure représente
l'influence des causes sur
l'affectation de personne
Par exemple :
L'augmentation de vitesse,
Le changement du
climat (pluie, neige.)
Nuit ou pendant la journée.





Cette figure représente l'influence du véhicule sur la gravité d'accident, son âge, son type d'énergie (petrol), sa marque











Chapitre 4 : Conculsion

L'informatique décisionnelle, désigne les moyens, les outils et les méthodes qui permettent de collecter, consolider, modéliser et restituer les données, matérielles ou immatérielles, d'une entreprise en vue d'offrir une aide à la décision et de permettre aux responsables de la stratégie d'entreprise d'avoir une vue d'ensemble de l'activité traitée

DataWareHouse: Pôle de données organisées spécifiquement pour répondre à des besoins décisionnels. Les données issues des sites de production sont extraites, transformées et enregistrées dans le data warehouse afin de permettre leurs analyses. Les données du data warehouse sont orientées sujet, intégrées, non volatiles, agrégées dans le temps et documentées.

Avantage:

- ♦ Données : consolidées, unifiées, historisées
- ♦ Analyses / restitutions faciles
- **♦** Solution mature
- ♦ Très adaptée aux données structurées voire semi-structurées

Inconvénients:

- ♦ Travail en amont conséquent (80% du temps et du coût) : analyse, conception, déploiement et maintenance
- ♦ Infrastructures coûteuses : nombreux outils à combiner